

دانشگاه ملی مهارت

آموزشگاه میناب

نام و نام خانوادگی : آرش زارعیان

واحد درسی : مباحث ویژه

رشته : مهندسی حرفه ای کامپیوتر

مدرس : محمد احمد زاده

بخش 4 Data Preprocessing :

- A. چرا Data Cleaning در علم داده اهمیت دارد؟
- B. Missing Values چگونه مدیریت می‌شوند؟
- C. Outliers چیست و چگونه می‌توانید آن‌ها را تشخیص دهید؟
- D. Data Transformation چرا کاربرد دارد؟
- E. Encoding Techniques (One-Hot Encoding) و Label Encoding چه تفاوتی دارند؟
- F. چرا Feature Selection در Model-building اهمیت دارد؟
- G. Duplicate Data چگونه در پایگاه داده‌ها حذف می‌شود؟
- H. Irrelevant Data چه مشکلاتی را در پیش‌بینی‌های Machine Learning ایجاد می‌کند؟
- I. چرا Data Imputation برای پر کردن Missing Values کاربرد دارد؟
- J. چگونه می‌توانید Normality را در داده‌های عددی بررسی کنید؟

مدرس: محمد احمدزاده

ترم بهمن ۱۴۰۳

Day... Month... Year...

Subject...

مباحث ویژه

بخش 4 Data Preprocessing

A: چرا Data cleaning در علم داده اهمیت دارد؟

Data cleaning یکی از مهم‌ترین مراحل در پردازش و تحلیل داده‌ها است. دلایل

اهمیت آن عبارت‌اند از:

۱- افزایش دقت مدل‌ها ۲- کاهش نویز و تفاوت‌ها ۳- بهبود عملکرد الگوریتم‌ها

۴- تصمیم‌گیری بهتر ۵- صرفه‌جویی در زمان و هزینه

به‌طور کلی، کیفیت داده‌ها تأثیر مستقیمی بر نتایج تحلیل و مدل‌های یادگیری ماشین دارد.

بخش پاکسازی شامل حذف داده‌های نادرست، تکمیل داده‌های ناقص و استاندارد کردن داده‌ها می‌باشد.

B: Missing Values چگونه مدیریت می‌شود؟

مدیریت مقادیر گم‌شده در داده‌ها بخش مهمی از پیش‌پردازش داده‌ها است. روش‌های

مختلفی برای برخورد با این مقادیر وجود دارد که بسته به نوع داده و کاربرد،

انتخاب می‌شوند.

Day... Month... Year...

Subject...

۱- روش‌های مدیریت مقادیر کم شده

۲- حذف داده‌های دارای مقدار کم شده: فریت: ساده و سریع عیب: ممکن است

۳- باعث از دست رفتن اطلاعات مهم شود

۴- جایگزینی: فریت: داده‌ها حفظ می‌شوند عیب: ممکن است دقت مدل کاهش یابد

۵- استفاده از مدل‌های پیش‌بینی: فریت: جایگزینی دقیق‌تر عیب: زمان برداشتن بالا

۶- استفاده از مقدار قبلی یا بعدی: فریت: مناسب برای داده‌های ترتیبی

۷- عیب: در صورت وجود تغییرات ناگهانی، ممکن است داده‌ها نادرست شوند

۸- استفاده از الویتم‌های مقاوم به مقادیر کم شده: فریت: کاهش نیاز به پیش‌پردازش

۹- عیب: همیشه بهترین نیست

۱۰- Outliers چیست و چگونه می‌توان آنها را تشخیص داد؟

۱۱- Outliers به نقاط داده‌ای گفته می‌شود که به طور قابل توجهی با سایر داده‌های موجود در یک

مجموعه داده تفاوت دارند. این نقاط می‌توانند به دلایل مختلفی مانند خطاهای اندازه‌گیری،

Day... Month... Year...

Subject...

۱- مورد اشتباه داده ها یا پدیده های واقعی در داده ها به وجود بیایند. راه های مختلفی برای

۳- شناسایی داده های پرت وجود دارد از جمله:

۵- آمارش آماری (محدوده بین چارکی - IQR) ۲- استفاده از انحراف معیار

۷- آمارش های صفتی بر مدل های یادگیری ماشین ۴- استفاده از نمودارها

۹- **Data transformation** کاربرد دارد؟

۱۱- **Data Transformation** فرایند تبدیل، تغییر یا نداشت داده ها به هدف صورت

۱۳- است که باعث بهبود تحلیل، مدل سازی، تفسیر داده ها می شود. این تبدیل می تواند شامل

۱۵- استاندارد سازی، نرمال سازی، تبدیل تناوبی، دسته بندی، رگرسیون و کاهش ابعاد باشد.

۱۷- کاربردهای مهم: ۱- بهبود دقت مدل های یادگیری ماشین ۲- مدیریت داده های پرت

۱۹- ۳- افزایش کارایی الگوریتم های مبتنی بر فاصله ۴- بهبود توزیع داده ها ۵- کاهش ابعاد و

۲۱- پیچیدگی داده ها ۶- سازگاری داده ها برای مدل های مختلف

۲۳- **Label Encoding** و **one-hot Encoding** چه تفاوتی با هم دارند؟

Day... Month... Year...

Subject...

1 هر دو روش برای تبدیل متغیرهای دسته‌بندی شده به داده‌های عددی استفاده می‌شوند اما

2
3 نحوه کاربرد و تبدیل آن‌ها متفاوت است.

Label

4
5 ~~Label~~ Encoding (رنگ‌آمیزی)

6
7 در این روش هر دسته (کلاس) به یک عدد صحیح اختصاص داده می‌شود.

8
9 مزایا: سادگی و کاهش ابعاد داده‌ها - مناسب برای مدل‌هایی که روابط ترتیبی و ادراک‌محوری ندارند

10
11 معایب: ایجاد ارتباط‌های عددی نادرست بین دسته‌ها

12
13 One-Hot Encoding (رنگ‌آمیزی تک‌محالی)

14
15 در این روش برای هر مقدار از متغیر دسته‌بندی شده، یک ویژگی ایجاد شده و مقدار آن یا 0 یا 1

16
17 به آن اختصاص می‌یابد

18
19 مزایا: از بین بردن ارتباط عددی نادرست بین دسته‌ها - مناسب برای مدل‌هایی که فرض می‌کنند

20
21 داده‌های ورودی مستقل از یکدیگرند

22
23 معایب: افزایش ابعاد داده، به خصوص در متغیرهای دسته‌بندی شده با تعداد زیاد

AVANGE

Day... Month... Year...

Subject...

ف. چرا Feature selection در Model-building اهمیت دارد؟

Feature selection فرایند انتخاب مهم‌ترین ویژگی‌ها از میان تمام ویژگی‌های موجود

در مجموعه داده است. این کار باعث بهبود کارایی مدل، کاهش پیچیدگی و جلوگیری از

overfitting می‌شود. فرای Feature selection در مدل‌سازی عبارت است از:

۱. کاهش ~~overfitting~~ overfitting ۲. بهبود دقت و عملکرد مدل

۳. کاهش زمان پردازش و هزینه محاسباتی ۴. بهبود تفسیرپذیری مدل

G Duplicate Data چگونه در پایگاه داده‌ها حذف می‌شود؟

داده‌های تکراری زمانی رخ می‌دهند که ردیف‌های مشابه یا یکسان در پایگاه داده ذخیره شوند.

حذف این داده‌ها برای بهبود کارایی، کاهش حجم داده‌ها و جلوگیری از تحلیل‌های نادرست ضروری است.

روش‌ها: ۱. استفاده از SQL برای حذف داده‌های تکراری

۲. حذف داده‌های تکراری در Pandas

۳. حذف داده‌های تکراری در Excel

Day... Month... Year...

Subject...

4. Irrelevant Data (موضوعات نامرتبط) - داده‌های بی‌ارتباطی در Machine Learning ایجاد می‌کند؟

Irrelevant Data (داده‌های نامرتبط) به ویژگی‌هایی گفته می‌شود که اطلاعات مفیدی

برای مدل یادگیری ماشین ارائه نمی‌دهند و حتی ممکن است باعث کاهش دقت مدل شوند.

این نوع داده‌ها معمولاً تولید ایجاد کرده و باعث کاهش کارایی، افزایش پیچیدگی و ایجاد

overfitting می‌شوند. موارد زیر مشکلات به وجود آمده می‌باشند:

۱. کاهش دقت مدل، ۲. افزایش overfitting، ۳. افزایش پیچیدگی محاسباتی

۴. سخت‌تر شدن تفسیر مدل، ۵. کاهش عملکرد مدل‌های مبتنی بر فاصله

5. Data Imputation (تکمیل داده‌های گمشده) - چرا؟

Data Imputation یک تکنیک مهم در پیش‌پردازش داده‌ها است که به جای حذف داده‌های ناقص

مقدارهای مناسب را جایگزین می‌کند. این کار باعث می‌شود داده‌های از دست رفته تأثیر منفی

روی دقت مدل نداشته باشند و به حفظ انیست و کامل بودن مجموعه داده کمک کند.

دلایل اهمیت و کاربرد: ۱. جلوگیری از کاهش حجم داده‌ها، ۲. بهبود دقت مدل یادگیری ماشین

Day... Month... Year...

Subject...

۳- جدولی از Bias در داده‌ها و افزایش پایداری و قابلیت تصمیم‌گیری

۴- چگونگی می‌تواند Normality را در داده‌های عددی بررسی کنید؟

Normality برای این معنی است که داده‌ها از یک توزیع نرمال پیروی می‌کنند بسیاری

از آزمون‌های پایداری ماشین (مانند رگرسیون خطی، ANOVA، آزمون‌های آماری پارامتریک)

فرض می‌کنند که داده‌ها دارای توزیع نرمال هستند برای بررسی نرمال بودن داده‌ها، می‌توان از

روش‌های آماری و گرافیکی استفاده کرد.

۵- روش‌های آماری گرافیکی

۱- رسم Histogram ۲- رسم Q-Q Plot (Quantile-Quantile Plot)

۳- روش‌های آماری

۱- آزمون شاپیرو-ویلک ۲- آزمون کولموگوروف-اسمیرنوف

۳- آزمون چارک-برا

۴- بررسی Skewness و Kurtosis

Day... Month... Year... Subject...

1 *Skewness* (چولگی): آن مقدار چولگی نزدیک به صفر باشد، داده ها متقارن و نرمال هستند.

2

3 *Kurtosis* (کُرتوس): آن مقدار کُرتوس نزدیک به 3 باشد، داده ها دارای توزیع نرمال هستند.

4

5

6

7

8

9

10

11

12

13

14

15

16

17

18

19

20

21

22

23

24

AVANGE